

Akıllı Şehir Aydınlatmasında Derin Pekiştirmeli Öğrenme: Berlin Örneği

ÖZET

Günümüzün hızla büyüyen şehirlerinde enerji yönetimi ve kamu güvenliği, kentsel altyapı sistemlerinin en temel iki önceliğini oluşturmaktadır. Bu çalışma, Berlin kentsel hareketlilik verileri kullanılarak, kentsel aydınlatma sistemlerinin enerji verimliliğini artırmayı ve trafik güvenliğini optimize etmeyi amaçlayan Derin Pekiştirmeli Öğrenme (DQN) tabanlı akıllı bir kontrol mekanizması geliştirmeyi hedeflemektedir. Araştırma kapsamında, TomTom servisinden elde edilen saat verisi, araç hızı ve trafik yoğunluğu verileri ile Open-Meteo servisinden sağlanan yağış ve hava durumu verileriyle birleştirilerek hibrit bir veri seti oluşturulmuştur. Geliştirilen Derin Pekiştirmeli Öğrenme modeli, Berlin'in altı aylık verileri üzerinde eğitilerek, ortamdaki değişkenlere göre aydınlatma seviyesini otonom bir şekilde optimize etmeyi öğrenmiştir. Elde edilen bulgular, modelin özellikle düşük trafik hacmi ve açık hava koşullarında ışık şiddetini kılarak önemli ölçüde enerji tasarrufu sağladığını; olumsuz hava koşulları ve yoğun trafik durumlarında ise güvenlik öncelikli davranarak aydınlatma seviyesini artırdığını kanıtlamaktadır. Çalışma, yapay zeka destekli otonom sistemlerin, kentsel enerji yönetimi ile güvenlik arasındaki dengeyi başarıyla kurabildiğini ve akıllı şehir uygulamaları için sürdürülebilir bir altyapı sunduğunu ortaya koymaktadır.

Anahtar Kelimeler: Derin Pekiştirmeli Öğrenme, Akıllı Şehirler, Enerji Optimizasyonu, Otonom Karar Mekanizmaları

1.Giriş

Kentleşmenin hızla artmasıyla birlikte enerji tüketiminin azaltılması ve şehir altyapılarının daha verimli yönetilmesi, akıllı şehir uygulamalarının temel araştırma alanlarından biri haline gelmiştir. Kurulu akıllı sokak lambalarının sayısının 2024 yılı sonunda 32,9 milyon iken, 2029 yılına kadar 85 milyon adede ulaşacağı öngörülmektedir [1]. Özellikle sokak aydınlatma sistemleri, şehirlerin toplam elektrik tüketiminin önemli bir bölümünü oluşturmakta olup, geleneksel aydınlatma yaklaşımlarında lambaların belirli zaman aralıklarında sabit parlaklık seviyesinde çalıştırılması gereksiz enerji tüketimine neden olmaktadır. Buna karşılık, trafik yoğunluğu, hava koşulları ve zamansal değişkenler dikkate alınarak aydınlatma seviyesinin dinamik olarak ayarlanması, hem enerji verimliliğinin artırılması hem de trafik güvenliğinin korunması açısından önemli avantajlar sunmaktadır.


Akıllı şehir teknolojilerindeki gelişmelerle birlikte, Nesnelerin İnterneti, sensör ağları ve bulut tabanlı veri platformları sayesinde trafik ve çevresel veriler gerçek zamanlı olarak toplanabilmektedir [2]. Bu verilerin yapay zekâ algoritmalarıyla analiz edilmesi, şehir altyapılarının çevresel koşullara uyum sağlayabilen otonom sistemlere dönüşmesini mümkün kılmaktadır. Özellikle trafik yoğunluğu, araç hızı, yağış miktarı ve hava durumu gibi çevresel değişkenler, yol aydınlatmasının optimum seviyede tutulabilmesi için önemli karar kriterleri arasında yer almaktadır.

Makine öğrenmesi tabanlı yöntemler son yıllarda akıllı aydınlatma sistemlerinde yaygın olarak kullanılmasına rağmen, bu yöntemlerin büyük bölümü denetimli öğrenme yaklaşımına dayanmaktadır [3]. Denetimli öğrenme algoritmaları geçmiş veriler üzerinden tahmin yapabilmekte, ancak çevrenin sürekli değiştiği dinamik sistemlerde karar mekanizmasını gerçek zamanlı olarak optimize etme konusunda sınırlı kalabilmektedir. Bu nedenle son yıllarda, çevreyle sürekli etkileşim kurarak deneyimlerinden öğrenebilen pekiştirmeli öğrenme yöntemleri akıllı şehir uygulamalarında giderek daha fazla ilgi görmektedir [4].

Derin Pekiştirmeli Öğrenme, klasik pekiştirmeli öğrenme algoritmalarının derin sinir ağları ile birleştirilmesi sonucunda yüksek boyutlu durum uzaylarında etkin karar verme yeteneği sunmaktadır [5]. Bu yöntemlerden biri olan Deep Q-Network, durum-eylem değer fonksiyonunu derin sinir ağı kullanarak öğrenmekte ve karmaşık çevrelerde optimum karar politikasını geliştirebilmektedir [6]. Experience Replay Buffer ve Epsilon-Greedy gibi mekanizmalar sayesinde öğrenme sürecinin kararlılığı artırılmakta, ajan hem yeni stratejileri keşfetmekte hem de elde ettiği deneyimleri kullanarak daha başarılı kararlar verebilmektedir [7]. Bu özellikleri nedeniyle DQN, enerji yönetimi, akıllı ulaşım sistemleri ve adaptif kontrol uygulamalarında yaygın olarak tercih edilmektedir [8].

Bu çalışmada, Berlin şehrine ait gerçek trafik verileri ile meteorolojik verileri bir araya getiren DQN tabanlı bir akıllı şehir aydınlatma sistemi önerilmektedir. Trafik hızı ve yoğunluğu TomTom API üzerinden, yağış ve hava durumu bilgileri ise Open-Meteo API üzerinden elde edilmiştir. Ayrıca saat bilgisi, çevrimsel yapısını koruyacak şekilde sinüs ve kosinüs dönüşümleri kullanılarak modele dâhil edilmiştir. Oluşturulan durum uzayı kullanılarak geliştirilen DQN ajanı, farklı trafik ve hava koşullarında en uygun aydınlatma seviyesini seçmeyi öğrenmektedir. Önerilen ödül mekanizması yalnızca enerji tüketimini azaltmayı değil, aynı zamanda sürüş güvenliğini de dikkate alarak karar verme sürecini yönlendirmektedir. Böylece sistem, değişen çevresel koşullara uyum sağlayabilen, enerji verimli ve güvenli bir adaptif aydınlatma yaklaşımı sunmaktadır.

Resim 1'de önerilen DQN tabanlı akıllı şehir aydınlatma sisteminin örnek çalışma senaryosu gösterilmektedir. Görüldüğü üzere araçların bulunduğu bölgelerde aydınlatma seviyesi artırılırken, trafik bulunmayan bölgelerde aydınlatma düşük seviyede tutularak enerji tasarrufu sağlanmaktadır. Bu yaklaşım sayesinde güvenlik gereksinimleri korunurken gereksiz enerji tüketiminin de önüne geçilmektedir. Son olarak, geliştirilen sistemin performansı ortalama ödül değerleri, aydınlatma seviyesi doğruluğu ve enerji verimliliği açısından değerlendirilmiş; elde edilen sonuçlar önerilen yöntemin dinamik şehir aydınlatma uygulamalarında etkili bir çözüm sunduğunu göstermiştir.




Resim 1. Önerilen Akıllı Şehir Aydınlatma Sisteminin Çalışma Senaryosu

2. Veri Seti

2.1 Trafik Verileri

TomTom, dijital haritalama ve trafik bilgisi teknolojileri alanında küresel çapta lider bir konumda olup, gerçek zamanlı trafik akış verileri sağlayan öncü bir kuruluştur [9]. Şirketin sunduğu trafik verileri; gelişmiş sensörler, araç içi navigasyon sistemleri ve anonimleştirilmiş konum bilgilerinin birleşimiyle elde edilen yüksek hassasiyetli bir trafik yoğunluk haritası oluşturur. Bu dinamik veri seti; araç hızları, trafik sıkışıklığı oranları ve yolculuk süreleri gibi kritik metrikleri kapsayarak şehir planlamacılarından yerel yönetimlere ve araştırmacılara kadar geniş bir kullanıcı kitlesine akıllı ulaşım çözümleri ve kentsel optimizasyon süreçleri için temel bir altyapı sunmaktadır. Resim 2’de TomTom Traffic Index platformu üzerinde gösterilen Berlin şehri trafik durum verileri gösterilmektedir. Bu araştırmanın uygulama aşamasında, TomTom'un veri havuzundan elde edilen Berlin şehrine ait 1 Ocak 2025 ile 30 Haziran 2025 tarihleri arasındaki 6 aylık dönemi kapsayan, toplam 4.343 adet veri satırı içeren trafik yoğunluğu verileri akıllı şehir aydınlatma optimizasyonu için temel bir girdi olarak kullanılmıştır. Bu kapsamda TomTom veri setinden doğrudan alınan aşağıdaki veriler kullanılmıştır.

- **Speed [kmh] (Hız):** Araçların o anki seyir hızıdır. Standartlaştırılmış (Z-skor) bir değer olduğu için ortalaması 0'dır. Pozitif değerler ortalamanın üstünde yüksek hızı, negatif değerler ise yavaşlamış trafiği temsil eder. Yapay zeka, düşük hızlarda (yüksek trafik veya yaya riski) aydınlatmayı daha dikkatli yönetmeyi öğrenir.
- **Congestion level [%] (Trafik Yoğunluğu):** Trafiğin sıkışıklık düzeyidir. Yine standartlaştırılmış bir değerdir. Yüksek trafik yoğunluğu, caddede daha fazla araç ve dolayısıyla daha fazla görünürlük ihtiyacı (güvenlik) demektir.
- **hour_sin (Sinüs) ve hour_cos (Kosinüs):** Saatin döngüsel pozisyonunun dikey ve yatay bileşleridir. Bu iki değer birlikte, modelin günün hangi vaktinde olduğunu (sabah, öğle, gece) hatasız bir şekilde anlamasını sağlar.




Resim 2. Berlin şehri trafik durum verileri

2.2 Hava Durumu Verileri

Resim 3’de Akıllı Şehir Aydınlatma projesinde kullanılan meteorolojik veri setlerinin kaynağı olan Open-Meteo arayüzü görülmektedir [10]. Open-Meteo, açık kaynaklı ve yüksek çözünürlüklü meteorolojik veri sağlayan, akademik araştırmalar ve veri bilimi projeleri için dünya çapında tercih edilen öncü bir iklim veri servisi. Şirketin sunduğu sistem; uydu ölçümleri, yer istasyonları ve sayısal hava tahmini modellerinin entegrasyonu, belirli bir koordinat için geçmişten günümüze yüksek hassasiyetli atmosferik veriler üretir. Bu dinamik veri havuzu; yağış miktarı, sıcaklık, rüzgar hızı ve görüş mesafesi gibi kritik parametreleri kapsayarak, meteorolojik değişkenlerin kentsel altyapı üzerindeki etkilerini analiz etmek isteyen araştırmacılar için güvenilir bir temel oluşturmaktadır. Bu araştırmanın uygulama aşamasında, Open-Meteo API’si üzerinden Berlin bölgesine ait 1 Ocak 2025 ile 30 Haziran 2025 tarihleri arasındaki meteorolojik gözlemler temin edilmiştir. Çalışmaya aşağıdaki veriler entegre edilmiştir.

- **precipitation (Yağış):** Milimetrik bazda yağış miktarıdır. Standartlaştırılmıştır. Değer arttıkça yapay zeka kötü hava koşullarının yarattığı riskleri hesaba katarak "Güvenlik Cezası" tetiklenmesin diye ışığı daha dikkatli yönetir.
- **weather_code (Hava Durumu Kodu):** Kategorik bir veridir. 0 (açık hava) ile 75 (yoğun kar) arasında değişir. Ajan, 51 ve üzerindeki kodları (yağışlı/karlı havalarda) "kötü hava" olarak tanımlayıp ışık seviyesini daha yüksek tutmaya çalışır.




Resim 3. Open-Meteo arayüzü

3. Metodoloji

Berlin Akıllı Şehir Aydınlatma projesi, kentsel altyapıyı optimize etmek amacıyla trafik ve meteorolojik verilerin karmaşık bir derin pekiştirmeli öğrenme mimarisiyle harmanlandığı, bir mühendislik çözümüdür. Resim 4’de gösterilen sistemin metodolojik temeli, TomTom API aracılığıyla sağlanan trafik hızı ve yoğunluk verilerinin, Open-Meteo API'den gelen yağış ve hava durumu kodlarıyla birleştirildiği çok boyutlu bir veri toplama sürecine dayanır. Bu süreçte zaman değişkenleri, saat verisinin 24 saatlik döngüsel doğasını korumak ve yapay zeka modelinin "saat 23:00'ten 00:00'a geçişi" gibi kritik zaman farklarını doğrusal kopukluk olarak algılamamasını sağlamak amacıyla sinüs ve kosinüs fonksiyonları kullanılarak trigonometrik dönüşüme tabi tutulmuştur. Temizlenen ve ölçeklendirilen bu veriler, Gymnasium standartlarına uygun bir çevre modeli olan veri seti içerisinde bir durum vektörü olarak inşa edilerek modelin çevresel farkındalığı sağlanmaktadır.

Eğitim sürecinin merkezinde, derin pekiştirmeli öğrenme literatüründe oldukça kararlı sonuçlar veren bir DQN (Deep Q-Network) ajanı yer almaktadır. Bu ajan, "Experience Replay Buffer" olarak adlandırılan gelişmiş bir hafıza mekanizması kullanarak, her adımda karşılaşılan durumları, yapılan eylemleri, elde edilen ödülleri ve bir sonraki durum geçişlerini bir depo yapısında saklar; bu sayede geçmiş deneyimler rastgele gruplar halinde yeniden eğitilerek modelin verilerin zamansal korelasyonuna sıkışıp kalması (overfitting) engellenir. Epsilon-Greedy politikasıyla yönetilen ajan, eğitim boyunca keşif ve sömürü dengesini kurarak, Q-Network'ünü sürekli olarak backpropagation ve Adam optimizasyon algoritmalarıyla güncelleyerek en uygun politika matrisine ulaşmaya çalışır.




Resim 4. Çalışmanın Metodolojisi

Sistemin davranışını belirleyen aksiyon uzayı, 0, 25, 50, 100 değerlerinden oluşan dört farklı aydınlatma seviyesiyle tanımlanmıştır; bu ayrık yapı, aydınlatma armatürlerinin gerçek dünyadaki kademeli çalışma yeteneklerini temsil eder ve DQN ajanı, anlık trafik ve hava durumuna göre bu dört seviyeden en optimal olanını seçerek kararlarını verir. Bu kararları yönlendiren ödül sistemi ise sadece enerji verimliliği odaklı olmayıp, kentsel güvenliği gözetken üçlü bir yapıda kurulmuştur. Ödül puanlama mantığında, ajanın seçtiği aydınlatma seviyesi verideki ideal değerle tam olarak eşleştiğinde sistem ajana +10 puan kazandırmakta, tam eşleşme sağlanamadığında ise ideal değer ile seçilen değer arasındaki farkın mutlak değerinin 25'e bölümünün negatifini ceza puanı olarak yansıtmaktadır. İkinci olarak, ajanın tercih ettiği aydınlatma şiddeti ideal değerden daha yüksek olduğunda, gereksiz enerji tüketimini engellemek adına sisteme -1 puanlık bir enerji israf cezası uygulanmaktadır. Üçüncü ve en kritik olanı ise, yağışlı ve düşük görüş mesafesinin olduğu riskli hava koşullarında ideal aydınlatma ihtiyacı sıfırdan büyük olmasına rağmen ajan aydınlatmayı tamamen kapatmayı (seviye 0) tercih ederse, sisteme -5 puanlık ağır bir güvenlik ihlali cezası uygulanmaktadır. Bu karmaşık ödül mekanizması, sistemi sadece bir "tasarruf aracı" olmaktan çıkarıp, değişen çevresel risk faktörlerini hesaplayan, dinamik ve akıllı bir kentsel yönetim birimine dönüştürmektedir. Nihai performans, ortalama ödül grafikleri, tahmin doğruluk eğrileri ve aydınlatma düzeyi sapma analizleri ile değerlendirilerek sistemin başarısı mühendislik standartlarında doğrulanmaktadır.

4. Bulgular

Resim 5’de derin pekiştirmeli öğrenme (DQN) ajanının 200 eğitim bölümü boyunca elde ettiği toplam ödül değerleri gösterilmektedir. Açık mavi çizgi her eğitim turunda elde edilen toplam ödülü, koyu mavi çizgi ise 10 turluk hareketli ortalamayı temsil etmektedir. Eğitimin ilk bölümlerinde ajan çevreyi keşfetme aşamasında olduğu için ödül değerlerinde büyük dalgalanmalar görülmektedir. Yaklaşık 20. bölümden sonra hareketli ortalamanın hızlı bir şekilde yükselmesi, ajanın çevreyi öğrenmeye başladığını göstermektedir. İlerleyen bölümlerde toplam ödül 400–440 aralığında kararlı bir seyir izlemekte ve yalnızca keşif stratejisinden (epsilon-greedy) kaynaklanan küçük dalgalanmalar gözlenmektedir. Eğitim sonunda hareketli ortalamanın yaklaşık 440 seviyesine ulaşması, DQN ajanının uygun aydınlatma kararlarını büyük ölçüde öğrenerek istikrarlı bir performans sergilediğini göstermektedir.



Resim 5. Toplam Ödül Grafiği

Resim 6’de sunulan canlı test çıktısı incelendiğinde, eğitilmiş derin pekiştirmeli öğrenme (DQN) ajanının çevresel değişkenleri son derece isabetli bir şekilde analiz ettiği ve veri setiyle tam uyumlu kararlar aldığı açıkça görülmektedir. Sisteme yansıyan anlık sensör verilerine göre; saat 02:00 itibarıyla trafik yoğunluğunun %16.4 gibi oldukça düşük bir seviyede seyrettiği ve ortalama araç hızının 47.5 km/s ile trafik akışının akıcı (sıkışksız) olduğu tespit edilmiştir. Aynı zamanda yağışın bulunmaması (0.00 mm) ve hava koşullarının olağan düzeyde (Hava Kodu: 3 - Bulutlu) olması, yoldaki sürüş güvenliğini tehdit edecek meteorolojik bir risk faktörü barındırmamaktadır. Gecenin ilerleyen saatleri olmasına rağmen, hem trafik hacminin düşüklüğü hem de olumlu hava şartları göz önüne alınarak veri setindeki ideal aydınlatma seviyesi %25 olarak belirlenmiştir. Yapay zeka modelinin de o anki durumu (state) başarıyla çözümleyerek birebir aynı oranda (%25) aydınlatma kararı aldığı ve bu doğru tahmini sayesinde maksimum başarı değeri olan 10.00 tam puanı kazandığı kaydedilmiştir. Bu sonuç, geliştirilen modelin sadece kuralları ezberlemediğini; aynı zamanda gecenin geç saatlerinde boş ve yağışsız bir yolda ışıkları tamamen açmanın (%100) bir enerji israfı olacağını kavrayarak, güvenlik ve enerji tasarrufu arasındaki optimum dengeyi başarıyla kurabildiğini kanıtlamaktadır.

Durum Verileri (Gerçeğe Uyarlanmış):

- Hız: 47.5 km/s
- Trafik Yoğunluğu: %16.4
- Yağış: 0.00 mm
- Hava Kodu: 3
- Saat: 02:00

[Verideki İdeal Işık] : %25.0

[Yapay Zeka Kararı] : %25

Alınan Puan : 10.00

Canlı Test Tamamlandı!

Resim 6. Canlı Test Gösterimi

5. Sonular ve Gelecek alıřmalar

Bu alıřmada, akıllı řehir aydınlatma sistemlerinin enerji verimliliğini artırmak ve aynı zamanda sürüş güvenliğini maksimum düzeyde tutmak amacıyla Derin Pekiřtirmeli Öğrenme tabanlı otonom bir karar mekanizması geliştirilmiştir. TomTom ve Open-Meteo servislerinden elde edilen gerçek zamanlı trafik yoğunluğu, araç hızı, meteorolojik koşullar ve zamansal döngü verileriyle eğitilen yapay zeka modeli; çevresel dinamikleri başarıyla analiz ederek optimum aydınlatma seviyelerini otonom bir şekilde belirlemeyi öğrenmiştir. Simülasyon ve canlı test bulguları, ajanın özellikle düşük trafik hacmi ve olumlu hava şartlarının olduėu gece saatlerinde aydınlatmayı kısararak ciddi bir enerji tasarrufu sağladığını; buna karşın olumsuz hava koşullarında veya yoğun trafikte güvenlik öncelikli davranarak ışık seviyesini artırdığını kanıtlamaktadır. Eğitim süreçlerine ait performans metrikleri, gereksiz verilerden arındırılmış modelin kısa sürede kararlı bir öğrenme profili sergilediğini ve kentsel enerji yönetimi ile güvenlik arasındaki optimum dengeyi başarıyla kurduğunu göstermektedir.

Gelecek alıřmalarda, geliştirilen bu tekil otonom modelin tüm řehir ağını ve birbirine baėlı kavřakları yönetecek şekilde Çoklu Ajanlı Pekiřtirmeli Öğrenme (Multi-Agent Reinforcement Learning) mimarilerine genişletilmesi planlanmaktadır. Ayrıca, sisteme yaya hareketliliğini algılayan görüntü işleme tabanlı kamera sistemleri veya çevresel ışık (LDR) sensör verilerinin entegre edilmesi, karar mekanizmasının hassasiyetini daha da ileriye taşıyacaktır. Algoritmik boyutta ise Derin Pekiřtirmeli Öğrenme modelinin performansının PPO (Proximal Policy Optimization) veya SAC (Soft Actor-Critic) gibi modern pekiřtirmeli öğrenme algoritmalarıyla karşılařtırılmalı olarak analiz edilmesi hedeflenmektedir. alıřmanın nihai hedefi olarak, eğitilmiş bu yapay zeka modelinin Nesnelerin İnterneti uç nokta cihazlarına yüklenerek pilot bir kentsel bölgede gerçek dünya saha testlerinin gerçekleştirilmesi öngörülmektedir.

Referanslar

- [1] <https://media.berginsight.com/2025/08/21130547/bi-streetlighting3-ps.pdf>
- [2] Zaman, M., Puryear, N., Abdelwahed, S., & Zohrabi, N. (2024). A review of IoT-based smart city development and management. *Smart Cities*, 7(3), 1462-1501.
- [3] Sen, S., Yadeo, D., Kumar, P., & Kumar, M. (2023). Machine learning and predictive control-based energy management system for smart buildings. In *Artificial intelligence and machine learning in smart city planning* (pp. 199-220). Elsevier.
- [4] Fang, P., Wang, M., Li, J., Zhao, Q., Zheng, X., & Gao, H. (2023). A distributed intelligent lighting control system based on deep reinforcement learning. *Applied Sciences*, 13(16), 9057.
- [5] Köylü, F., & Atıkan, Y. (2024). Otonom araçlarda derin pekiştirmeli öğrenme yöntemleri ile sollama. *Niğde Ömer Halisdemir Üniversitesi Mühendislik Bilimleri Dergisi*, 13(2), 429-439.
- [6] Fan, J., Wang, Z., Xie, Y., & Yang, Z. (2020, July). A theoretical analysis of deep Q-learning. In *Learning for dynamics and control* (pp. 486-489). PMLR.
- [7] Perkins, D., Escobar, O. J., & Green, L. (2025). DQN Performance with Epsilon Greedy Policies and Prioritized Experience Replay. *arXiv preprint arXiv:2511.03670*.
- [8] Liu, J., Chen, H. M., Li, S., & Lin, S. (2021, October). Adaptive and Energy-Saving Smart Lighting Control Based on Deep Q-Network Algorithm. In *2021 6th International Conference on Control, Robotics and Cybernetics (CRC)* (pp. 207-211). IEEE.
- [9] <https://www.tomtom.com/traffic-index/city/berlin/>
- [10] <https://open-meteo.com/>